

# Rapport d'analyse sc RNA-seq : Typage cellulaire à partir d'IL2R et autres marqueurs

Par Isabella Raevel, Eve-Angeline Stephen et Anaïs Storp

Sciences des données et Intelligence artificielle

**Date :** 8 mai 2025

LU3DS004

Sarah Ouadah, Raphaël Fournier-S'niehotta



# Table des matières

|          |                                                                                                     |           |
|----------|-----------------------------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduction</b>                                                                                 | <b>2</b>  |
| <b>2</b> | <b>Questions de recherche</b>                                                                       | <b>3</b>  |
| <b>3</b> | <b>Analyses menées</b>                                                                              | <b>4</b>  |
| 3.1      | Prétraitement des données . . . . .                                                                 | 4         |
| 3.1.1    | Filtrage des cellules . . . . .                                                                     | 4         |
| 3.1.2    | Normalisation des données . . . . .                                                                 | 5         |
| 3.2      | Réduction de dimension et clustering . . . . .                                                      | 5         |
| 3.3      | Fonctions d’analyses et de visualisation . . . . .                                                  | 6         |
| 3.3.1    | Visualisation UMAP colorée . . . . .                                                                | 6         |
| 3.3.2    | Distribution de l’expression par cluster . . . . .                                                  | 6         |
| 3.3.3    | Carte thermique de l’expression moyenne . . . . .                                                   | 7         |
| 3.3.4    | Repartition globale des types cellulaires . . . . .                                                 | 7         |
| 3.3.5    | Annotation automatique des clusters . . . . .                                                       | 7         |
| 3.4      | Analyses statistiques : tests d’expression différentielle et corrélations . . . . .                 | 8         |
| 3.4.1    | Comparaison des niveaux d’expression entre clusters : t-test et test de Mann-Whitney . . . . .      | 9         |
| 3.4.2    | Corrélations entre gènes . . . . .                                                                  | 9         |
| <b>4</b> | <b>Résultats et Interprétation</b>                                                                  | <b>10</b> |
| 4.1      | Contrôle qualité avant et après nettoyage des données . . . . .                                     | 10        |
| 4.2      | Visualisation de l’expression des récepteurs IL-2 . . . . .                                         | 11        |
| 4.2.1    | Méthodologie de visualisation . . . . .                                                             | 11        |
| 4.2.2    | Segmentation des cellules en clusters et annotation immunologique . . . . .                         | 11        |
| 4.2.3    | Expression de IL2RA (chaîne $\alpha$ ) . . . . .                                                    | 12        |
| 4.2.4    | Expression de IL2RB (chaîne $\beta$ ) . . . . .                                                     | 12        |
| 4.2.5    | Expression de IL2RG (chaîne $\gamma$ ) . . . . .                                                    | 12        |
| 4.2.6    | Carte thermique de l’expression moyenne des marqueurs . . . . .                                     | 13        |
| 4.2.7    | Conclusion visuelle croisée . . . . .                                                               | 13        |
| 4.3      | Analyse différentielle d’expression des gènes <i>IL2RA</i> , <i>IL2RB</i> et <i>IL2RG</i> . . . . . | 14        |
| 4.3.1    | Visualisation de l’expression génique par cluster . . . . .                                         | 14        |
| 4.3.2    | Quantification statistique de l’expression par cluster . . . . .                                    | 14        |
| 4.3.3    | Jeu : <i>Cross-tissue immune cell analysis</i> (multi-tissus adultes) . . . . .                     | 14        |
| 4.3.4    | Jeu : <i>Human early embryogenesis</i> . . . . .                                                    | 15        |
| 4.3.5    | Jeu : <i>Human kidney scRNA-seq</i> . . . . .                                                       | 16        |
| 4.3.6    | Jeu : <i>Spatially organized immune hubs (colorectal cancer)</i> . . . . .                          | 16        |
| 4.3.7    | Conclusion de l’analyse différentielle . . . . .                                                    | 17        |
| 4.4      | Interpretation générale des résultats des jeux de données . . . . .                                 | 17        |
| <b>5</b> | <b>Conclusion</b>                                                                                   | <b>18</b> |
|          | <b>Annexes</b>                                                                                      | <b>19</b> |
|          | <b>Annexe complémentaire – Jeu embryonnaire</b>                                                     | <b>43</b> |
| <b>A</b> | <b>Références bibliographiques</b>                                                                  | <b>46</b> |

# 1 Introduction

Dans le cadre de notre UE *Projet IA et Sciences des données*, nous avons choisi de travailler sur une thématique à la croisée de l'immunologie et de l'analyse de données : la quantification et l'étude de la distribution des récepteurs à l'interleukine-2 (IL-2) à l'échelle cellulaire. Les maladies auto-immunes regroupent plus de 80 pathologies dans lesquelles le système immunitaire se dérègle et attaque les cellules de l'organisme. Elles touchent entre 5 et 10 % de la population mondiale, avec une nette prédominance féminine (environ 80 % des cas). Si l'immunothérapie est aujourd'hui bien établie en cancérologie, son application aux maladies auto-immunes reste complexe, notamment à cause de la difficulté à réguler finement la réponse immunitaire sans risque d'effets indésirables.

L'IL-2 est une cytokine clé du système immunitaire adaptatif, impliquée dans la survie, la prolifération et l'activation des lymphocytes T notamment les T effecteurs (Teff) et les T régulateurs (Treg). Son effet dépend du type de récepteur auquel elle se lie. Ces récepteurs sont constitués de trois sous-unités : IL2RA (CD25), IL2RB (CD122) et IL2RG (CD132). Les Treg, qui expriment de manière continue le récepteur trimérique à haute affinité, captent efficacement l'IL-2 pour moduler et limiter les réponses immunitaires excessives. Les Teff, quant à eux, n'expriment ce récepteur complet qu'en phase d'activation, ce qui augmente leur sensibilité à l'IL-2. Le bon équilibre entre ces deux types de lymphocytes est essentiel : trop de Teff peut favoriser des réactions auto-immunes tandis qu'un excès de Treg peut conduire à une immunosuppression excessive.

Notre objectif est donc de quantifier et localiser l'expression des récepteurs IL-2 dans différentes populations cellulaires humaines, afin de mieux comprendre leur rôle dans la régulation immunitaire et d'envisager de nouvelles pistes thérapeutiques. Pour cela, nous utilisons des données issues du *single-cell RNA sequencing* (scRNA-seq), une technologie qui permet de mesurer l'expression des gènes cellule par cellule et de révéler toute la complexité des tissus. Chaque jeu de données se présente sous forme de matrices (gènes en lignes, cellules en colonnes), accompagnées de fichiers « barcodes » pour identifier les cellules, et « features » pour les noms de gènes. Nous nous appuyons sur plusieurs ensembles de données, principalement issus du Human Cell Atlas. Chacune d'entre nous s'est concentrée sur un ou plusieurs jeux : Eve-Angéline analyse deux jeux, l'un issu de tumeurs colorectales et l'autre du développement embryonnaire humain ; Isabella étudie des données du rein humain (divisées en trois sous-unités anatomiques) ; Anaïs se penche sur des échantillons de sang périphérique. En combinant ces sources variées, nous espérons cartographier finement l'expression des récepteurs IL-2 selon les tissus et contextes biologiques, identifier les types cellulaires impliqués, et mieux comprendre les mécanismes immunitaires à l'échelle unicellulaire, avec à terme des applications potentielles en immunothérapie et dans le traitement des maladies auto-immunes.

## 2 Questions de recherche

Dans le prolongement de notre analyse, plusieurs questions de recherche ont émergé pour orienter l'exploration biologique et statistique autour des récepteurs à l'interleukine-2. La première question que nous nous sommes posée est la suivante : *les cellules T expriment-elles davantage de récepteurs IL-2 que les cellules B dans nos jeux de données ?* L'idée serait ici de vérifier si comme le suggère la littérature, les cellules T présentent en moyenne une expression plus élevée des trois sous-unités IL2RA, IL2RB et IL2RG.

Une autre question porte sur *la possibilité qu'un type cellulaire exprime simultanément les trois récepteurs dans l'ensemble des jeux analysés*. Nous cherchons à savoir s'il existe une sous-population identifiable comme les T régulateurs caractérisée par une forte co-expression de ces trois gènes.

Enfin, une dernière interrogation concerne la *régularité d'expression d'IL2RG par rapport aux deux autres sous-unités*. Nous souhaitons déterminer si IL2RG en tant que composant partagé par plusieurs récepteurs de cytokines est exprimé de manière plus homogène dans l'ensemble des types cellulaires. Ces trois questions structurent la suite de notre étude et guideront les analyses visuelles, statistiques et biologiques que nous avons mises en place pour mieux comprendre le rôle des récepteurs IL-2 dans les tissus explorés.

## 3 Analyses menées

L'analyse s'est déroulée selon une pipeline structurée, pensée comme un enchaînement logique et reproductible d'étapes, allant du nettoyage des données brutes jusqu'à l'annotation finale des types cellulaires. Dans le cadre d'une analyse de données issues du séquençage single-cell RNA-seq, la mise en place d'une pipeline rigoureuse n'est pas un simple choix technique, mais une nécessité méthodologique. Les données single-cell sont en effet caractérisées par leur complexité, leur volume, et leur forte hétérogénéité. À chaque étape – filtrage, normalisation, réduction de dimension, clustering, annotation – des biais ou erreurs peuvent se propager s'ils ne sont pas correctement maîtrisés. La pipeline a donc été conçue pour être à la fois robuste, c'est-à-dire capable de produire des résultats fiables même face à des variations dans les données, et réutilisable, afin qu'elle puisse être appliquée à d'autres jeux de données de même nature.

L'objectif principal de cette analyse était de détecter, classifier et caractériser les différentes sous-populations cellulaires présentes dans un échantillon multi-tissulaire humain. L'approche par clustering non supervisé, combinée à une annotation automatique basée sur des marqueurs immunitaires, permet d'identifier des types cellulaires connus, mais aussi potentiellement des sous-types moins documentés. Une attention particulière a été portée à l'étude des récepteurs de l'interleukine-2 (IL-2), notamment IL2RA, IL2RB et IL2RG, dont la présence ou l'absence est fortement corrélée à des fonctions spécifiques du système immunitaire adaptatif, en particulier les cellules T régulatrices (Tregs), les T effectrices, ou encore les cellules activées.

Construire une pipeline complète autour de ces objectifs permet non seulement d'aboutir à une interprétation biologique cohérente, mais aussi de garantir la reproductibilité de l'analyse, un critère fondamental en science des données. Cela ouvre également la voie à une automatisation partielle du processus, rendant ce type d'analyse plus accessible pour des études comparatives à plus grande échelle.

### 3.1 Prétraitement des données

Avant toute analyse, une étape de contrôle qualité rigoureuse a été appliquée aux données brutes. Ce prétraitement constitue une phase absolument essentielle dans toute étude fondée sur des données de type single-cell RNA-seq. En effet, contrairement aux approches en vrac, les données single-cell capturent des profils transcriptomiques au niveau individuel, ce qui rend les résultats extrêmement sensibles à la qualité des cellules incluses dans l'analyse. Un nettoyage mal réalisé peut conduire à des artefacts, à des regroupements erronés ou à une interprétation biologique faussée.

#### 3.1.1 Filtrage des cellules

Le premier critère de filtrage repose sur le nombre de gènes exprimés par cellule. Les cellules exprimant très peu de gènes (généralement moins de 200) sont considérées comme non fiables. Ces profils appauvris peuvent résulter d'un échec de capture, d'un stress cellulaire important, ou d'une cellule en fin de vie. Les inclure dans l'analyse fausserait les distributions et les regroupements. À l'inverse, les cellules exprimant un nombre de gènes très élevé (souvent supérieur à 2500) sont également suspectes. Il s'agit très souvent de doublets, c'est-à-dire de deux cellules capturées ensemble et analysées comme une seule. Leur profil d'expression combine alors artificiellement les signaux de deux types cellulaires, ce qui peut générer des clusters aberrants ou intermédiaires[1] [3].

Un deuxième filtre fondamental concerne l'expression des gènes mitochondriaux. Lorsqu'une cellule subit un stress important ou entre en apoptose, elle a tendance à dégrader son ARN cytoplasmique, tandis que les transcrits mitochondriaux, plus stables, deviennent surreprésentés. Une proportion élevée de gènes mitochondriaux (généralement au-delà de 5 % de l'expression totale) est donc un marqueur indirect de mauvaise qualité cellulaire [1] [2]. L'exclusion de ces cellules permet d'améliorer la robustesse des analyses en aval, notamment les regroupements (clustering) et les visualisations.

Ces filtres sont standards dans le domaine du single-cell RNA-seq et sont essentiels pour garantir la qualité des données avant toute analyse ultérieure. Ils permettent de s'assurer que les cellules incluses dans l'analyse sont fiables et représentatives des populations cellulaires étudiées [4].

### 3.1.2 Normalisation des données

Une fois ce filtrage qualitatif appliqué, les données sont normalisées afin de rendre les profils d'expression comparables entre cellules. En effet, chaque cellule présente une profondeur de séquençage différente : certaines ont été très bien capturées, d'autres beaucoup moins. Pour corriger ces disparités, nous avons appliqué une normalisation [13], accompagnée d'une transformation logarithmique. Dans notre cas, nous avons utilisé une transformation de type 'log1p', soit  $\log(x + 1)$ , qui permet de ramener les grandes valeurs à une échelle plus réduite tout en conservant l'information relative entre les gènes. Cette étape est essentielle pour atténuer les effets des valeurs extrêmes (outliers), mais aussi pour permettre une analyse correcte des distances entre cellules, notamment lors de la réduction de dimension et du clustering. La normalisation est particulièrement importante pour les jeux de données single-cell RNA-seq, car elle permet de comparer les expressions géniques entre cellules de manière équitable. Sans normalisation, les cellules avec une profondeur de séquençage plus élevée pourraient dominer les analyses, ce qui pourrait fausser les résultats. La transformation logarithmique, quant à elle, aide à stabiliser la variance des données, ce qui est crucial pour les analyses statistiques ultérieures. La combinaison de ces étapes produit un jeu de données à la fois nettoyé, équilibré et exploitable pour les analyses statistiques et biologiques ultérieures. Ces prétraitements sont essentiels pour garantir la robustesse et la fiabilité des résultats obtenus à partir des données single-cell RNA-seq.

## 3.2 Réduction de dimension et clustering

Après le prétraitement et la normalisation, les données restent extrêmement complexes : chaque cellule est décrite par l'expression de plusieurs milliers de gènes, ce qui rend leur exploration directe difficile et peu informative. Pour rendre ces données analysables, nous avons mis en œuvre une réduction de dimension en deux étapes, suivie d'un algorithme de clustering non supervisé.

Dans un premier temps, nous avons appliqué la méthode *Truncated Singular Value Decomposition* (TruncatedSVD), particulièrement adaptée aux matrices creuses comme celles générées par les données single-cell RNA-seq [5]. Cette méthode de réduction linéaire permet de compresser l'information, d'atténuer le bruit technique et de réduire la redondance entre gènes fortement corrélés. En transformant les données dans un espace à plus faible dimension tout en conservant les structures globales, elle prépare efficacement le jeu de données pour les méthodes de réduction non linéaire [6].

Nous avons ensuite utilisé la méthode UMAP (Uniform Manifold Approximation and Projection), une technique non linéaire bien adaptée à la visualisation de données biologiques

complexes. Contrairement à TruncatedSVD, UMAP conserve à la fois les relations locales et globales entre les points, ce qui en fait un outil de choix pour révéler les structures latentes dans les données transcriptomiques single-cell [7]. Cette méthode projette les cellules dans un espace à deux dimensions de manière à ce que les cellules ayant des profils transcriptomiques similaires apparaissent proches les unes des autres. La projection obtenue est particulièrement intuitive et lisible, permettant une interprétation visuelle directe des regroupements cellulaires.

Sur cette base, nous avons appliqué l’algorithme de K-Means pour regrouper les cellules selon leurs similarités d’expression. K-Means est une méthode itérative qui attribue chaque cellule au centre de cluster le plus proche, selon une distance euclidienne minimale. Cette technique est simple, rapide, et particulièrement performante lorsque les données ont été préalablement projetées dans un espace réduit tel que celui produit par UMAP.

Nous avons choisi d’utiliser 45 clusters, un paramètre fixé de manière empirique après plusieurs essais successifs. Le choix du nombre de clusters repose sur un équilibre entre deux exigences contradictoires : d’une part, obtenir une granularité suffisante pour capturer la diversité des sous-populations cellulaires, et d’autre part, éviter un sur-clustering qui pourrait fragmenter artificiellement des groupes homogènes. Cette décision a été guidée par l’inspection visuelle des projections UMAP, la cohérence des profils d’expression génique dans chaque cluster, ainsi que la stabilité des regroupements observés lors de tests de robustesse (par exemple, en relançant K-Means avec différentes initialisations).

Ce niveau de découpage nous a permis de révéler des sous-types cellulaires pertinents d’un point de vue biologique, tout en assurant une lisibilité claire de la structure globale de l’échantillon. En résumé, l’enchaînement TruncatedSVD  $\rightarrow$  UMAP  $\rightarrow$  K-Means a permis de transformer un ensemble massif de données brutes en une représentation interprétable, ouvrant la voie à une annotation fonctionnelle fine et reproductible.

### 3.3 Fonctions d’analyses et de visualisation

Afin de mieux comprendre les résultats du clustering et d’interpréter biologiquement les types cellulaires identifiés, nous avons mis en place plusieurs fonctions de visualisation, chacune répondant à des objectifs spécifiques. Ces outils sont essentiels dans l’analyse de données single-cell, où les résultats peuvent être massifs, multidimensionnels et difficiles à lire sans représentation graphique adaptée.

#### 3.3.1 Visualisation UMAP colorée

Cette fonction permet de projeter l’expression d’un gène donné directement sur la carte UMAP précédemment obtenue. Le principe est simple : à chaque cellule est associée une intensité de couleur correspondant à son niveau d’expression pour le gène ciblé. On obtient ainsi une carte où les zones de forte ou faible expression sont visibles spatialement. Cette visualisation est extrêmement utile, notamment dans le cas des gènes fonctionnels comme IL2RA ou FOXP3, qui ne sont exprimés que dans des sous-ensembles cellulaires bien définis (par exemple les Tregs). Cela permet de localiser visuellement les sous-populations exprimant un marqueur donné, sans avoir à consulter une table chiffrée ou parcourir cluster par cluster.

#### 3.3.2 Distribution de l’expression par cluster

Pour explorer la distribution de l’expression d’un gène dans chaque cluster, nous avons utilisé des violin plots. Ce type de graphique est particulièrement adapté aux données single-cell, qui sont souvent peu symétriques, bruitées, et très dispersées. Contrairement à un simple

histogramme ou boxplot, un violin plot affiche la densité de probabilité de l'expression dans chaque cluster tout en montrant les valeurs individuelles (via un jitter ou stripplot). Cela permet de voir à la fois la médiane, la dispersion, et la concentration des valeurs, en un seul graphique. Cette fonction a été utilisée notamment pour observer les récepteurs IL-2, et a permis de repérer visuellement les clusters dans lesquels ces récepteurs étaient fortement exprimés, et ceux où ils étaient absents ou silencieux.

### 3.3.3 Carte thermique de l'expression moyenne

La heatmap (carte thermique) est une méthode classique mais extrêmement efficace pour comparer l'expression moyenne d'un ensemble de gènes entre plusieurs groupes. Ici, chaque ligne représente un cluster, chaque colonne un gène, et la couleur traduit l'intensité moyenne d'expression. L'intérêt de cette approche dans notre contexte est qu'elle permet, en un coup d'œil, de repérer les groupes de cellules qui co-expriment plusieurs marqueurs immunitaires. Par exemple, un cluster exprimant à la fois CD3E, CD8A et GZMB est probablement un sous-type de T CD8 effecteur. Ce type de visualisation est également utile pour guider l'annotation automatique, en confirmant des hypothèses de typage cellulaire basées sur les marqueurs.

### 3.3.4 Repartition globale des types cellulaires

Enfin, une fonction simple mais informative a permis de visualiser la distribution des types cellulaires dans l'échantillon. En comptant le nombre de cellules annotées pour chaque type, et en les représentant sous forme de barplot, nous obtenons une vue d'ensemble de la composition cellulaire. Cela permet de répondre à des questions globales, comme : quelles sont les populations majoritaires ? Y a-t-il un déséquilibre en faveur de certaines sous-populations ? Cette information est particulièrement utile si l'on souhaite comparer plusieurs échantillons ou conditions expérimentales. Les visualisations jouent un rôle fondamental dans l'analyse des données single-cell. Elles ne servent pas uniquement à illustrer les résultats : elles permettent de comprendre, valider, comparer et interpréter les structures biologiques identifiées par les algorithmes. En combinant des outils classiques (UMAP, heatmaps) à des outils plus spécifiques aux données single-cell (violin plots), nous avons pu mener une exploration visuelle complète, en parallèle de notre annotation automatique. Cette approche renforce la cohérence et la pertinence biologique de nos conclusions.

### 3.3.5 Annotation automatique des clusters

Une fois le clustering effectué, une étape clé consiste à interpréter le contenu biologique de chaque cluster. Le regroupement par K-Means fournit des structures statistiques, mais ne renseigne pas directement sur le type cellulaire représenté par chaque groupe. Pour répondre à cette question, nous avons conçu une fonction d'annotation automatique, capable de typer chaque cluster en fonction de l'expression moyenne de marqueurs immunitaires connus.

Le fonctionnement de cette fonction repose sur une logique simple mais puissante : pour chaque cluster, nous calculons la moyenne d'expression d'un ensemble de gènes marqueurs bien établis dans la littérature. Ces gènes ont été sélectionnés car ils permettent de distinguer de manière robuste les grandes familles cellulaires immunitaires (T cells, B cells, monocytes, NK cells...), mais aussi certains sous-types fonctionnels (Tregs, Tfh, naïves, effecteurs...). Les bases de données telles que CellMarker [8] et le Human Protein Atlas [9] fournissent des ressources précieuses pour l'identification de ces marqueurs.

Une fois ces moyennes calculées, une série de conditions logiques est appliquée pour identifier le type cellulaire le plus probable. Par exemple, un cluster affichant une forte expression conjointe de CD3E (marqueur des T cells), CD8A (co-récepteur des T CD8), PRF1 (perforine) et GZMB (granzyme B) est très probablement composé de cellules T CD8+ effectrices. Cette combinaison de gènes reflète un profil cytotoxique actif, typique des T effecteurs en phase d'activation.

De la même manière, un cluster présentant une forte expression de FOXP3, IL2RA (CD25) et TNFRSF4 (OX40) est annoté comme Treg activée. FOXP3 est un facteur de transcription spécifique des T régulatrices, IL2RA en est un marqueur de surface classique, et TNFRSF4 reflète un état d'activation. Cette triade permet d'identifier les Tregs avec un bon niveau de précision.

D'autres logiques similaires ont été implémentées pour identifier :

- Les B cells, par l'expression de CD19 et MS4A1 (CD20).
- Les monocytes classiques et non classiques, via CD14 et CD16.
- Les cellules NK, par NCAM1 (CD56) et FCGR3A (CD16).
- Les T CD4+ naïves, par CCR7 et SELL (CD62L).
- Les T folliculaires helper (Tfh), via CXCR5 et ICOS.
- Les plasmocytes, grâce à des gènes comme XBP1, MZB1 et CD38.

Chaque règle est basée sur des seuils d'expression définis empiriquement (par exemple, "fortement exprimé" si la moyenne dépasse une certaine valeur), mais reste entièrement ajustable. Le système permet donc d'être modulable, extensible, et compatible avec différents panels de gènes.

L'un des grands avantages de cette approche est sa reproductibilité : l'annotation ne dépend pas d'une inspection visuelle subjective mais d'un ensemble de critères standardisés. De plus, cette annotation peut être appliquée automatiquement à de nouveaux jeux de données, à condition qu'ils soient normalisés de manière cohérente. Cela permet d'automatiser le typage cellulaire à grande échelle.

En pratique, cette fonction a rendu l'analyse beaucoup plus lisible. Elle permet d'associer à chaque cluster un nom biologique directement exploitable : "Treg", "CD4+ naïve", "B cells", etc., ce qui facilite non seulement la visualisation des résultats (par exemple dans les UMAP annotés ou les heatmaps), mais aussi l'interprétation biologique. Elle permet également de repérer des sous-populations inattendues, ou des clusters qui ne correspondent à aucun type bien défini, et qui pourront faire l'objet d'analyses plus poussées.

Ainsi, cette étape d'annotation automatique transforme une analyse statistique en une lecture biologique interprétable, en rapprochant les résultats numériques des connaissances issues de l'immunologie. [10]

### 3.4 Analyses statistiques : tests d'expression différentielle et corrélations

Afin de renforcer l'interprétation biologique des résultats obtenus à travers la pipeline de clustering et d'annotation [11], nous avons intégré une série de tests statistiques classiques. Ces tests ont pour but de vérifier de manière rigoureuse si certains gènes sont significativement plus exprimés dans un cluster donné, et d'identifier les relations éventuelles entre différents marqueurs. Cette étape statistique vient en appui des observations visuelles (violin plots, heatmaps) et permet de valider objectivement les différences d'expression.

### 3.4.1 Comparaison des niveaux d'expression entre clusters : t-test et test de Mann-Whitney

Pour évaluer si certains gènes étaient significativement plus exprimés dans certains clusters que dans d'autres, nous avons eu recours à deux approches statistiques complémentaires : le t-test de Student et le test de Mann-Whitney. Ces deux tests permettent de comparer l'expression d'un gène donné entre un cluster d'intérêt et le reste de l'échantillon, mais selon des hypothèses statistiques différentes.

Le t-test a été utilisé pour comparer les moyennes d'expression, en partant du principe que les données sont distribuées de façon à peu près normale. Par exemple, nous avons appliqué ce test au gène IL2RA pour déterminer si son expression était significativement plus élevée dans un cluster donné (comme celui des Tregs) par rapport aux autres. Cette méthode a permis d'identifier des gènes différentiellement exprimés avec précision, notamment lorsqu'elle était accompagnée d'une correction pour les tests multiples afin de limiter les faux positifs.

Le test de Mann-Whitney, lui, a été utilisé comme alternative non paramétrique [16]. Il présente l'avantage de ne faire aucune hypothèse sur la distribution des données — un point particulièrement important dans le contexte du single-cell RNA-seq, où l'expression génique est souvent très variable et asymétrique. Ce test compare les distributions d'expression entre deux groupes de manière robuste, même en présence de valeurs extrêmes ou de variabilité importante.

En combinant ces deux approches, nous avons pu confirmer de manière rigoureuse les différences d'expression observées visuellement (dans les violin plots ou les heatmaps) et valider, sur le plan statistique, l'identification de sous-populations cellulaires spécifiques. [12]

### 3.4.2 Correlations entre gènes

En complément des comparaisons inter-clusters, nous avons également analysé la corrélation entre les gènes d'intérêt. Cette analyse permet de déterminer si l'expression de certains marqueurs est liée au sein de l'échantillon, ce qui peut révéler une co-régulation ou une activation conjointe de certains programmes cellulaires. Nous avons utilisé le coefficient de corrélation de Pearson, qui mesure la force et la direction de la relation linéaire entre deux variables. Les résultats ont été représentés sous forme de matrice de corrélation annotée (heatmap), facilitant l'interprétation.

## 4 Résultats et Interprétation

### Présentation des jeux de données

Afin de cartographier l'expression des récepteurs de l'interleukine-2 (IL-2) dans divers contextes biologiques, nous avons exploité plusieurs jeux de données de transcriptomique à cellule unique (scRNA-seq). Chacun d'eux couvre des sources tissulaires variées — allant de tissus adultes à des échantillons embryonnaires — permettant une analyse comparative riche selon l'origine cellulaire et le type immunitaire.

Chaque jeu comprend :

- une matrice d'expression génique (gènes en lignes, cellules en colonnes),
- des fichiers **barcodes** (identifiants de cellules),
- et des fichiers **features** (noms de gènes).

Ils ont été choisis pour leur diversité cellulaire, leur pertinence en immunologie, et leur accessibilité via des plateformes publiques reconnues. Le tableau ci-dessous résume leurs caractéristiques :

| Jeu de données                                                                                                            | Cellules | Gènes  | Origine tissulaire |
|---------------------------------------------------------------------------------------------------------------------------|----------|--------|--------------------|
| <i>Single-cell RNA sequencing of the human kidney</i><br><a href="#">Human Cell Atlas - Kidney</a>                        | 33 538   | 25 404 | Rein humain        |
| <i>Single-cell atlas of human early embryogenesis</i><br><a href="#">Human Cell Atlas</a>                                 | 185 140  | 32 351 | Embryon humain     |
| <i>Cross-tissue immune cell analysis</i><br><a href="#">SCP1845 - Single Cell Portal</a>                                  | 329 762  | 36 601 | 16 tissus adultes  |
| <i>Spatially organized multicellular immune hubs in colorectal cancer</i><br><a href="#">SCP1162 - Single Cell Portal</a> | 371 223  | 43 282 | Côlon humain       |

TABLE 1 – Caractéristiques principales des jeux de données single-cell utilisés dans cette étude.

Ces jeux de données constituent la base de l'ensemble des analyses exploratoires, statistiques et visuelles que nous détaillons ci-après.

#### 4.1 Contrôle qualité avant et après nettoyage des données

Une étape fondamentale dans l'analyse single-cell RNA-seq est le contrôle qualité initial, visant à éliminer les cellules peu fiables ou artefactuelles. Pour chaque échantillon, nous avons évalué trois critères principaux : le nombre de gènes détectés par cellule, le nombre total d'UMI (Unique Molecular Identifiers) et le pourcentage de gènes mitochondriaux.

Des seuils de filtrage ont été définis pour supprimer :

- les cellules exprimant très peu de gènes (cellules mortes ou partiellement lysées) ;
- celles exprimant un trop grand nombre de gènes ou d'UMI (souvent des doublets) ;
- et celles ayant une proportion trop élevée de gènes mitochondriaux (supérieure à 10 % dans la plupart des cas).

Les distributions de ces indicateurs sont représentées en annexe, avant et après application des filtres. Ces visualisations permettent de valider le bon nettoyage des données en observant l'élimination des outliers et la recentration des distributions autour de valeurs biologiquement plausibles.

Les figures 1 à 8 illustrent cette amélioration du signal de manière claire pour les trois échantillons : Multi-tissus, rein, embryons et côlon humain.

## 4.2 Visualisation de l'expression des récepteurs IL-2

L'un des objectifs centraux de notre étude étant de mieux comprendre la distribution fonctionnelle des récepteurs à l'interleukine-2 (IL-2) à l'échelle unicellulaire, nous avons visualisé l'expression génique des trois sous-unités qui composent ces récepteurs : **IL2RA** (CD25), **IL2RB** (CD122) et **IL2RG** (CD132). Ces gènes codent respectivement pour les chaînes  $\alpha$ ,  $\beta$  et  $\gamma$  du récepteur de l'IL-2, et leur combinaison détermine la sensibilité des cellules à cette cytokine. Leur co-expression est notamment un marqueur des lymphocytes T régulateurs (Tregs), tandis que d'autres types cellulaires, comme les T CD8 ou les cellules NK, expriment préférentiellement certaines sous-unités selon leur état d'activation.

### 4.2.1 Méthodologie de visualisation

Pour chaque gène, les niveaux d'expression ont été projetés sur les cartes UMAP construites précédemment. Avant cette projection non linéaire, une première réduction de dimension a été réalisée à l'aide de la méthode *TruncatedSVD*, particulièrement adaptée aux matrices creuses générées par les données single-cell. Cette étape, représentées pour les différents jeux en annexe fig. 9, fig. 10, fig. 11 permettent de condenser l'information et de supprimer les dimensions redondantes, tout en préservant les structures principales des données.

Cette étape a permis de projeter les données dans un espace de dimension intermédiaire, facilitant l'application ultérieure d'UMAP. Dans ces représentations bidimensionnelles, chaque point correspond à une cellule individuelle, colorée selon son intensité d'expression du gène d'intérêt. Cette approche permet de superposer une information fonctionnelle à la structure transcriptionnelle globale, en repérant directement les zones (ou clusters) où un gène est fortement exprimé.

Les figures UMAP sont disponibles en annexe pour chacun des trois gènes et pour chacun des trois échantillons analysés : échantillon multi-tissus (fig. 14), échantillon Rein (fig. 12), échantillon embryonnaire (fig. 13) et côlon (fig. 15).

### 4.2.2 Segmentation des cellules en clusters et annotation immunologique

Afin de faciliter l'analyse fonctionnelle des récepteurs IL-2, il est essentiel de comprendre comment les cellules ont été regroupées et caractérisées. Après la réduction de dimension par *TruncatedSVD*, les données ont été projetées dans un espace UMAP à deux dimensions. Sur cette carte, chaque cellule est représentée par un point positionné selon la similarité de son profil transcriptomique global.

Un algorithme de clustering non supervisé (**K-Means**) a ensuite été appliqué sur l'espace UMAP pour regrouper les cellules en sous-populations distinctes. Cette étape permet d'identifier des structures internes dans le jeu de données et de faire émerger des regroupements biologiquement pertinents.

Les figures suivantes (en annexe) montrent la division des cellules en clusters :

— Jeu multi-tissus : fig. 16

- Jeu rein : [fig. 17](#)
- Jeu embryonnaire : [fig. 18](#)
- Jeu colon : [fig. 19](#)

À partir de ces clusters, une étape d’annotation automatique a été réalisée pour attribuer à chaque groupe un type cellulaire immunitaire probable. Cette annotation repose sur l’expression moyenne de gènes immunitaires bien connus.

La méthode d’annotation utilisée se base sur des règles conditionnelles simples : par exemple, un cluster présentant une forte expression conjointe de CD3E et CD8A est typé comme T CD8+, tandis qu’un cluster exprimant FOXP3, IL2RA et TNFRSF4 est typé comme Treg. Cela permet une classification rapide, reproductible, et adaptée à des jeux de données de grande taille.

Les résultats de cette annotation sont visibles dans les figures suivantes :

- Jeu multi-tissus : [fig. 20](#)
- Jeu rein : [fig. 21](#)
- Jeu embryonnaire : [fig. 22](#)
- Jeu côlon : [fig. 23](#)

Cette double visualisation – d’abord par cluster, puis par type cellulaire – nous permet de valider la cohérence biologique des regroupements. Elle sert également de socle interprétatif pour l’analyse génique spécifique, notamment l’étude des récepteurs IL-2, qui dépend fortement de l’identité cellulaire de chaque cluster.

#### 4.2.3 Expression de IL2RA (chaîne $\alpha$ )

L’expression d’IL2RA apparaît très focalisée sur certains clusters bien délimités, en particulier dans les jeux multi-tissus et rein. Cette concentration spatiale correspond vraisemblablement aux lymphocytes T régulateurs (Tregs), qui expriment en permanence cette sous-unité à haute affinité, même en l’absence d’activation. Dans le jeu moelle/foie, l’expression est plus dispersée mais reste identifiable dans des zones compatibles avec des Tregs activés.

La visualisation d’IL2RA confirme donc son rôle de marqueur discriminant des Tregs, mais suggère aussi sa présence dans certaines sous-populations T CD8 activées ou dans des monocytes activés, comme observé dans les données embryonnaires. Ce point sera approfondi dans l’analyse différentielle.

#### 4.2.4 Expression de IL2RB (chaîne $\beta$ )

Contrairement à IL2RA, l’expression d’IL2RB est plus diffuse et moins strictement localisée. On l’observe notamment dans des clusters identifiés comme lymphocytes T CD8 effecteurs ou cellules NK. Cela est cohérent avec la littérature : la sous-unité  $\beta$  du récepteur de l’IL-2 est exprimée par des cellules effectrices activées, souvent en réponse à des signaux pro-inflammatoires ou cytotoxiques.

Dans l’échantillon multi-tissus, cette expression est marquée dans les clusters cytotoxiques, tandis que dans les données embryonnaires, elle semble apparaître dans des sous-ensembles indéterminés, suggérant des profils transitionnels ou des précurseurs immunitaires. Son rôle dans ces contextes reste à mieux caractériser.

#### 4.2.5 Expression de IL2RG (chaîne $\gamma$ )

IL2RG, enfin, présente une expression beaucoup plus ubiquitaire. Cette sous-unité est en effet commune à plusieurs récepteurs de cytokines (IL-2, IL-4, IL-7, IL-9, IL-15, IL-21), ce qui explique sa présence dans une grande variété de cellules immunitaires. Toutefois, bien que

largement exprimée, elle conserve un certain pouvoir discriminant : son niveau d'expression est particulièrement élevé dans les cellules T activées, les NK, et certaines populations T mémoire.

Cette expression généralisée fait d'IL2RG un bon marqueur de fond immunitaire, mais son interprétation nécessite de la croiser avec les profils d'IL2RA et IL2RB pour identifier les cellules ayant réellement un récepteur fonctionnel complet.

#### 4.2.6 Carte thermique de l'expression moyenne des marqueurs

Pour évaluer globalement l'expression des marqueurs immunitaires dans les différentes sous-populations cellulaires, nous avons construit une carte thermique (heatmap) présentant l'expression moyenne de chaque gène d'intérêt dans chacun des clusters identifiés. Cette représentation synthétique permet de visualiser les profils transcriptionnels caractéristiques des groupes cellulaires, facilitant leur annotation et leur interprétation biologique.

La figure en annexe *Carte thermique – Expression moyenne des marqueurs par cluster* présente en abscisse les gènes sélectionnés (IL2RA, IL2RB, IL2RG, CD3E, CD4, CD8A, CD19, MS4A1, ICAM1, NCAM1, CD14) et en ordonnée les 45 clusters issus du clustering. La couleur indique l'intensité moyenne d'expression du gène dans chaque cluster : plus la teinte tend vers le rouge, plus l'expression est élevée.

L'analyse de cette heatmap révèle plusieurs tendances intéressantes :

- Les clusters **2**, **8**, **12**, **18** et **20** montrent une forte co-expression de **IL2RG**, ce qui suggère qu'ils correspondent probablement à des sous-populations de lymphocytes T activés ou régulateurs (Tregs). L'expression de **CD3E** des clusters **2**, **8**, **12**, **16** et **23** dans les clusters en commun renforce cette hypothèse.
- Le cluster **41** présente une forte expression de **CD19** et **MS4A1**, marqueurs typiques des cellules B. Sa faible expression des récepteurs IL-2 est cohérente avec un phénotype B différencié non impliqué dans la signalisation IL-2 dépendante.
- Le cluster **42** se démarque avec une forte expression de **MS4A1** et une très forte valeur pour **IL2RB**, ce qui pourrait indiquer une sous-population B particulière activée ou en transition fonctionnelle.
- Le cluster **35**, qui exprime fortement **CD8A**, **CD3E** et **IL2RB**, est vraisemblablement composé de cellules T CD8+ effectrices, connues pour leur capacité cytotoxique et leur réponse à l'IL-2 via la sous-unité  $\beta$ .
- Enfin, des marqueurs myéloïdes comme **CD14** sont très faiblement exprimés dans l'ensemble des clusters, suggérant que les cellules myéloïdes sont peu représentées dans cet échantillon.

Cette carte permet donc une validation croisée entre les marqueurs utilisés pour l'annotation automatique, les profils d'expression des récepteurs IL-2, et les hypothèses biologiques formulées à partir des visualisations UMAP. Elle constitue un outil essentiel pour affiner l'identification des sous-populations et renforcer la cohérence des résultats dans un cadre exploratoire.

#### 4.2.7 Conclusion visuelle croisée

L'analyse UMAP de ces trois gènes permet de valider visuellement plusieurs hypothèses : la spécificité d'IL2RA pour les Tregs, le rôle effecteur d'IL2RB, et la fonction partagée d'IL2RG. Elle permet également de détecter des sous-populations atypiques, ou de vérifier la cohérence entre annotation automatique et expression génique.

Ces cartes constituent ainsi une étape clé dans la confirmation fonctionnelle des types cellulaires identifiés et préparent le terrain pour les analyses statistiques différentielles qui suivent.

### 4.3 Analyse différentielle d'expression des gènes *IL2RA*, *IL2RB* et *IL2RG*

L'analyse visuelle des cartes UMAP, bien qu'informatrice, reste essentiellement qualitative. Pour compléter cette approche, nous avons réalisé une quantification statistique rigoureuse de l'expression des sous-unités du récepteur IL-2, à travers les différents clusters cellulaires identifiés. L'objectif est d'évaluer, de manière robuste, si certains types cellulaires expriment significativement plus l'un ou plusieurs de ces gènes, et ainsi de conforter les hypothèses fonctionnelles issues de l'annotation automatique.

#### 4.3.1 Visualisation de l'expression génique par cluster

L'expression des gènes *IL2RA* (fig. 24, fig. 26, fig. 25, fig. 33), *IL2RB* (fig. 27, fig. 29, fig. 28, fig. 34) et *IL2RG* (fig. 30, fig. 32, fig. 31, fig. 35) a d'abord été projetée sur les cartes UMAP, permettant de visualiser la répartition spatiale des cellules exprimant chacun de ces marqueurs. Ces projections révèlent des zones d'expression spécifiques : par exemple, des îlots d'expression dense d'*IL2RA* dans des clusters compatibles avec les Tregs, ou une expression plus diffuse mais ciblée d'*IL2RB* dans les cellules cytotoxiques.

Ces observations qualitatives orientent ensuite la phase de quantification.

#### 4.3.2 Quantification statistique de l'expression par cluster

Pour objectiver ces tendances, nous avons utilisé des diagrammes en violon (*violin plots*) illustrant la distribution des niveaux d'expression de chaque gène, cluster par cluster. Ces graphiques permettent de visualiser la médiane, la dispersion, ainsi que la densité de l'expression dans chaque sous-population.

Afin de déterminer si un gène est significativement plus exprimé dans un cluster donné que dans le reste de l'échantillon, nous avons appliqué un test non paramétrique de **Mann–Whitney** (aussi appelé test de Wilcoxon), particulièrement adapté à la nature asymétrique et bruitée des données single-cell RNA-seq.

Les clusters présentant une expression significativement plus élevée que le fond sont indiqués par une astérisque dans les figures en annexe :

- **Multi-tissus** : fig. 36, fig. 37, fig. 38 ;
- **Rein humain** : fig. 39, fig. 40, fig. 41 ;
- **Côlon humain** : fig. 42, fig. 43, fig. 44.
- **Embryons humain** : fig. 45, fig. 46, fig. 47.

Ces visualisations permettent de quantifier les différences d'expression observées précédemment dans les cartes UMAP et d'en confirmer la significativité statistique. Elles fournissent également une base pour une analyse fonctionnelle plus fine, en reliant les marqueurs du récepteur IL-2 à des types cellulaires spécifiques.

#### 4.3.3 Jeu : *Cross-tissue immune cell analysis* (multi-tissus adultes)

L'échantillon issu de l'analyse immunitaire multi-tissulaire représente une grande diversité cellulaire, couvrant un large éventail de tissus adultes. Cette richesse se reflète dans les profils d'expression des sous-unités du récepteur de l'IL-2, qui révèlent des spécialisations transcriptionnelles nettes et biologiquement cohérentes.

Le gène **IL2RA**, codant pour la chaîne  $\alpha$  du récepteur, est exprimé de manière marquée dans plusieurs clusters bien délimités. Ces clusters sont majoritairement annotés comme lymphocytes

T régulateurs (Tregs), ce qui concorde parfaitement avec le rôle connu d'IL2RA en tant que marqueur classique de cette population. On observe également une expression non négligeable dans certains clusters de lymphocytes T CD8 activés, ce qui suggère un rôle d'IL2RA dans les phases précoces d'activation cytotoxique, comme décrit dans la littérature.

La chaîne  $\beta$ , **IL2RB**, présente une expression plus diffuse mais clairement enrichie dans des clusters associés à des cellules T CD8 effectrices et à des cellules NK. Cette distribution conforte sa fonction dans la signalisation intermédiaire du récepteur de l'IL-2, nécessaire à l'activation des cellules à potentiel cytotoxique.

Enfin, l'expression de **IL2RG**, codant pour la chaîne  $\gamma$  commune, est observée de manière quasi ubiquitaire dans l'ensemble des clusters à composante immunitaire. Bien que son profil soit moins discriminant que ceux d'IL2RA ou IL2RB, cette omniprésence est en accord avec son rôle fondamental en tant que composant partagé par plusieurs récepteurs de cytokines, essentiels à la signalisation dans divers types de cellules T, B et NK.

Ainsi, cette analyse confirme la complémentarité fonctionnelle des trois sous-unités : une expression restreinte et spécifique pour IL2RA, plus large pour IL2RB, et universelle pour IL2RG – dessinant une architecture modulable du récepteur IL-2 selon le type et l'état cellulaire.

#### 4.3.4 Jeu : *Human early embryogenesis*

Dans le contexte particulier du développement embryonnaire, l'interprétation des profils d'expression génique se heurte à une forte hétérogénéité cellulaire ainsi qu'à l'absence d'annotations systématiques pour plusieurs clusters. Ce jeu de données explore des stades précoces de différenciation, où les identités cellulaires sont encore en construction, rendant l'analyse plus exploratoire.

L'expression du gène **IL2RA** (chaîne  $\alpha$ ), bien que moins marquée que dans les échantillons adultes, est néanmoins significative dans deux clusters. L'un de ces groupes pourrait correspondre à des monocytes embryonnaires ou à des cellules myéloïdes en cours de différenciation. Cette localisation inattendue suggère un rôle potentiel d'IL2RA dans la régulation de l'hématopoïèse précoce, ou bien reflète un état transitoire d'activation dans des précurseurs immunitaires.

Le gène **IL2RB** (chaîne  $\beta$ ) présente une expression diffuse dans l'ensemble du jeu, sans enrichissement net dans des clusters annotés. Toutefois, la présence de ce marqueur dans des populations encore non identifiées soulève l'hypothèse de l'émergence de lignages cytotoxiques précoces, comme les cellules T CD8+ ou NK embryonnaires. Une annotation plus précise de ces groupes serait nécessaire pour affiner cette interprétation.

Enfin, la chaîne commune **IL2RG** conserve un patron d'expression large, cohérent avec son rôle ubiquitaire dans la signalisation cytokine. On observe toutefois une surexpression relative dans certains clusters, possiblement associés à des cellules NK ou à des lymphocytes T naïfs en formation. Ce profil conforte l'idée que même à un stade embryonnaire, certaines structures du système immunitaire commencent à se mettre en place.

Ainsi, bien que plus complexe à interpréter, ce jeu de données embryonnaire suggère l'activation précoce de programmes cytokiniques et l'existence de sous-populations immunitaires émergentes exprimant déjà les composantes du récepteur IL-2.

Une [analyse complémentaire détaillée](#) a été réalisée pour approfondir ces résultats en s'appuyant sur l'origine tissulaire fournie dans les métadonnées.

#### 4.3.5 Jeu : *Human kidney scRNA-seq*

Dans ce jeu de données issu de tissu rénal, les profils d'expression des gènes **IL2RA**, **IL2RB** et **IL2RG** suggèrent la présence d'une infiltration immunitaire modérée, potentiellement liée à des mécanismes locaux de surveillance ou à un état inflammatoire chronique.

Le gène **IL2RA** (chaîne  $\alpha$ ) est détecté dans plusieurs clusters annotés comme lymphocytes T, mais également dans un sous-ensemble de monocytes classiques. Cette co-expression peut refléter un état d'activation des Tregs dans le microenvironnement rénal, ainsi qu'un possible recrutement monocyttaire en réponse à un stress tissulaire ou à un processus de remodelage local.

Le gène **IL2RB** (chaîne  $\beta$ ) est fortement exprimé dans des clusters identifiés comme lymphocytes T CD8<sup>+</sup>, en particulier ceux coexprimant *CD8A* et *GZMB*. Ce profil est typique des cellules T cytotoxiques effectrices, qui utilisent cette sous-unité pour répondre à des concentrations intermédiaires d'IL-2 dans les tissus périphériques.

Enfin, **IL2RG** (chaîne  $\gamma$ ), sous-unité commune à plusieurs récepteurs de cytokines, montre une expression large dans l'ensemble des cellules immunitaires du rein, avec un pic d'expression marqué chez les lymphocytes T. Ce schéma est en accord avec son rôle central dans la signalisation des interleukines impliquées dans la prolifération et la survie cellulaire.

En résumé, l'expression conjointe de ces trois gènes dans le tissu rénal reflète une activité immunitaire significative, mettant en évidence des sous-populations T activées ou régulatrices ainsi que des monocytes en interaction avec le compartiment lymphocytaire.

Cependant, l'analyse montre que malgré un filtrage préalable visant à ne conserver que les cellules immunitaires, la majorité des clusters restent annotés comme « Autres/Indéterminé ». Les marqueurs immunitaires classiques présentent en effet une expression strictement nulle dans ces groupes, comme le confirme une heatmap de l'expression moyenne. Ces clusters correspondent probablement à des cellules non immunitaires, à du bruit technique, ou à des cellules mal captées lors de l'échantillonnage, ce qui expliquerait l'absence de structure claire sur la carte UMAP ainsi que le faible signal observé dans les *violin plots* des récepteurs **IL2RA** et **IL2RB**. Le signal biologique d'intérêt est ainsi noyé dans une proportion importante de données peu informatives, ce qui dégrade la lisibilité globale des visualisations.

On peut raisonnablement conclure que les cellules contenues dans ces clusters ne sont probablement pas d'origine immunitaire.

#### 4.3.6 Jeu : *Spatially organized immune hubs (colorectal cancer)*

Ce jeu de données, issu de biopsies de tumeurs colorectales, met en lumière un microenvironnement tumoral riche en cellules immunitaires et fortement structuré. L'analyse différentielle de l'expression des sous-unités du récepteur à l'IL-2 y révèle des dynamiques immunitaires complexes, caractéristiques des tissus néoplasiques infiltrés.

L'expression de **IL2RA** (chaîne  $\alpha$ ) est particulièrement marquée dans plusieurs clusters bien définis, en grande partie annotés comme lymphocytes T régulateurs (Tregs). Cette forte présence des Tregs au sein du tissu tumoral est en accord avec leur rôle reconnu dans l'immunosuppression locale : ils freinent l'activité des lymphocytes cytotoxiques et facilitent la progression tumorale en échappant à la surveillance immunitaire.

Le gène **IL2RB** (chaîne  $\beta$ ) présente également un niveau d'expression élevé, notamment dans des clusters identifiés comme cellules T CD8<sup>+</sup> activées. Cela indique qu'en parallèle d'un climat immunosuppresseur, certains compartiments tumoraux sont le siège d'une activité cytotoxique potentiellement dirigée contre les cellules cancéreuses.

Quant à **IL2RG** (chaîne  $\gamma$ ), son expression ubiquitaire dans ce contexte est cohérente avec son rôle de co-récepteur partagé entre plusieurs voies cytokiniques. On observe cependant des pics d'expression plus intenses dans des clusters annotés comme cellules T effectrices et cellules NK infiltrantes, deux populations impliquées dans la lutte anti-tumorale.

En somme, ce jeu illustre la coexistence, typique des tumeurs solides, d'un front cytotoxique actif (via les T CD8+ et NK) et d'un contre-pouvoir immunosuppresseur orchestré par les Tregs, comme en témoignent les profils différenciés d'expression des trois sous-unités du récepteur à l'IL-2.

#### 4.3.7 Conclusion de l'analyse différentielle

L'ensemble de ces résultats confirme une organisation fonctionnelle fine des sous-unités du récepteur IL-2 à travers différents contextes tissulaires. Leur distribution différentielle – spécifique pour *IL2RA* et *IL2RB*, ubiquitaire pour *IL2RG* – offre des clés de lecture précieuses pour distinguer les rôles respectifs de chaque population cellulaire.

Cette quantification statistique vient conforter l'annotation automatique des clusters et constitue une base solide pour des explorations biologiques plus poussées, notamment en immunothérapie ou en recherche translationnelle.

### 4.4 Interpretation générale des résultats des jeux de données

L'analyse des jeux de données complémentaires confirme les observations issues du jeu principal, tout en mettant en lumière certaines spécificités liées au contexte tissulaire et à l'origine des cellules.

Le gène **IL2RA**, codant pour la chaîne  $\alpha$  du récepteur de l'IL-2 et considéré comme un marqueur d'activation des cellules T, est systématiquement retrouvé dans des populations de lymphocytes T. Il est également exprimé chez certains monocytes, comme observé dans les jeux 2 et 3. Cette distribution suggère un état d'activation ou un phénotype régulateur de ces cellules dans des contextes tissulaires particuliers. Son expression restreinte à un nombre limité de clusters renforce son rôle comme composant discriminant du récepteur à haute affinité, potentiellement impliqué dans des réponses immunitaires spécifiques.

Le gène **IL2RB**, codant pour la chaîne  $\beta$ , présente une expression plus large, bien que majoritairement spécifique des cellules T CD8<sup>+</sup>. Ce pattern est particulièrement marqué dans les jeux 3 et 4. Dans le jeu 2, son expression est détectée dans plusieurs clusters non annotés de manière certaine, ce qui met en évidence l'importance de l'annotation rigoureuse dans ce type d'analyse. L'ensemble des résultats suggère que la chaîne  $\beta$  est associée à des cellules à potentiel effecteur ou cytotoxique.

Le gène **IL2RG**, enfin, confirme son expression ubiquitaire. Il est exprimé dans une grande variété de cellules immunitaires, notamment les cellules NK et les lymphocytes T. Cette distribution large est cohérente entre les différents jeux de données et s'aligne avec son rôle en tant que chaîne  $\gamma$  commune à plusieurs récepteurs de cytokines. Sa présence dans la quasi-totalité des clusters souligne sa fonction essentielle dans la signalisation et l'homéostasie immunitaires.

En résumé, cette analyse multi-données met en évidence que la distribution différenciée des trois sous-unités du récepteur de l'IL-2 reflète une hiérarchie fonctionnelle entre les types cellulaires. Une cartographie fine de leur expression permet ainsi de mieux caractériser les fonctions spécifiques de chaque sous-population immune. Ces résultats pourraient constituer une base pertinente pour des approches thérapeutiques ciblant sélectivement certaines branches de la voie IL-2.

## 5 Conclusion

Ce projet nous a offert l’opportunité d’approfondir notre compréhension du rôle des récepteurs de l’interleukine-2 (IL-2) dans divers contextes immunologiques, en combinant des compétences en bioinformatique, en immunologie et en analyse de données single-cell RNA-seq. En mobilisant plusieurs jeux de données de transcriptomique unicellulaire issus de tissus variés — sains, embryonnaires, tumoraux ou multi-organes — nous avons pu cartographier avec une grande précision l’expression des trois sous-unités majeures du récepteur IL-2 : **IL2RA** (chaîne alpha), **IL2RB** (chaîne bêta) et **IL2RG** (chaîne gamma commune).

L’approche méthodologique adoptée — allant du prétraitement rigoureux des données à l’annotation automatique des clusters cellulaires — a permis de révéler des signatures transcriptionnelles distinctes pour chaque gène. **IL2RA** se démarque par son expression ciblée dans les cellules T régulatrices (Tregs) et dans certains T CD8 activés, marquant un état d’activation ou de régulation immune. **IL2RB**, quant à lui, est enrichi dans les cellules à activité cytotoxique, notamment les T CD8 effecteurs. Enfin, **IL2RG**, véritable pivot cytokinaire, présente une expression ubiquitaire au sein des populations immunitaires, ce qui corrobore son rôle en tant que sous-unité partagée entre plusieurs récepteurs de cytokines.

Cette distribution complémentaire reflète une hiérarchie fonctionnelle dans la signalisation de l’IL-2, conditionnée à la fois par le type cellulaire et le microenvironnement tissulaire. Nos analyses, confirmées par des visualisations UMAP, des tests statistiques et des projections par cluster, soulignent l’importance de contextualiser l’expression génique à l’échelle unicellulaire pour mieux appréhender les fonctions immunitaires fines.

Au-delà des résultats biologiques, ce projet illustre la puissance des outils single-cell dans la recherche biomédicale moderne. La pipeline développée, flexible et reproductible, pourra être facilement réutilisée pour des études similaires, par exemple dans l’évaluation de réponses immunitaires sous traitement, la caractérisation de tumeurs immunoévasives, ou encore dans l’étude de pathologies auto-immunes.

Enfin, cette démarche nous a permis de consolider nos compétences dans des domaines clés : le traitement de données à haut débit, l’automatisation de l’annotation cellulaire, la visualisation avancée de données complexes, ainsi que l’interprétation biologique intégrée. En somme, ce travail représente un aboutissement à la fois scientifique et méthodologique, ouvrant la voie à des applications futures en immunothérapie personnalisée et en médecine de précision.

# Annexes

## Contrôle qualité avant et après nettoyage




FIGURE 1 – Contrôle qualité initial – Échantillon multi-tissus : distributions avant nettoyage.




FIGURE 2 – Contrôle qualité après filtrage – Échantillon multi-tissus .




FIGURE 3 – Contrôle qualité initial – Échantillon rénal : avant nettoyage.




FIGURE 4 – Contrôle qualité après nettoyage – Échantillon rénal .




FIGURE 5 – Contrôle qualité initial – Échantillon embryonnaire : avant nettoyage.




FIGURE 6 – Contrôle qualité après nettoyage – Échantillon embryonnaire .




FIGURE 7 – Contrôle qualité avant nettoyage – Échantillon côlon .




FIGURE 8 – Contrôle qualité après nettoyage – Échantillon côlon .

## Réduction de dimension : TruncatedSVD et UMAP

*Remarque importante* : dans les visualisations suivantes, les figures sont annotées comme « PCA », mais il s'agit en réalité de projections obtenues via la méthode **Truncated Singular Value Decomposition (TruncatedSVD)**.




FIGURE 9 – TruncatedSVD – Jeu de données sur le rein : projection dans l'espace des deux premières composantes principales.




FIGURE 10 – TruncatedSVD – Jeu de données sur les embryons humains : projection selon les deux axes principaux de variance.




FIGURE 11 – TruncatedSVD – Jeu de données sur le côlon humain : projection selon les deux axes principaux de variance.




FIGURE 12 – UMAP – Jeu de données rein : projection en 2D illustrant les regroupements cellulaires.




FIGURE 13 – UMAP – Jeu de données embryonnaire : projection UMAP des cellules basée sur leur expression génique.




FIGURE 14 – UMAP – Jeu de données multi-tissus : projection finale des cellules dans l'espace UMAP.




FIGURE 15 – UMAP – Jeu de données côlon : projection finale des cellules dans l’espace UMAP.

## Clustering et annotation cellulaire




FIGURE 16 – UMAP par cluster – Jeu de données (multi-tissus).




FIGURE 17 – UMAP par cluster – Jeu de données (rein).




FIGURE 18 – UMAP par cluster – Jeu de données (embryonnaire).




FIGURE 19 – UMAP par cluster – Jeu de données (Colon).




FIGURE 20 – Annotation cellulaire automatique – Jeu de données multi-tissus : typage selon les marqueurs immunitaires.




FIGURE 21 – Annotation cellulaire automatique – Jeu de données rein : typage des sous-populations immunitaires.




FIGURE 22 – Annotation cellulaire automatique – Jeu de données côlon : classification des types cellulaires dominants.




FIGURE 23 – Annotation cellulaire automatique – Jeu de données embryonnaire : classification des types cellulaires dominants.

## Annexe : Visualisation de l'expression des gènes IL2RA, IL2RB, IL2RG

UMAP colorée par l'expression génique




FIGURE 24 – UMAP colorée par l'expression de **IL2RA** – Jeu multi-tissus




FIGURE 25 – UMAP colorée par l'expression de **IL2RA** – Jeu embryonnaire




FIGURE 26 – UMAP colorée par l'expression de **IL2RA** – Jeu rénal




FIGURE 27 – UMAP colorée par l'expression de **IL2RB** – Jeu multi-tissus




FIGURE 28 – UMAP colorée par l'expression de **IL2RB** – Jeu embryonnaire




FIGURE 29 – UMAP colorée par l'expression de **IL2RB** – Jeu rénal




FIGURE 30 – UMAP colorée par l'expression de **IL2RG** – Jeu multi-tissus




FIGURE 31 – UMAP colorée par l'expression de **IL2RG** – Jeu embryonnaire




FIGURE 32 – UMAP colorée par l'expression de **IL2RG** – Jeu rénal




FIGURE 33 – UMAP colorée par l'expression de **IL2RA** – Jeu côlon




FIGURE 34 – UMAP colorée par l'expression de **IL2RB** – Jeu côlon




FIGURE 35 – UMAP colorée par l'expression de **IL2RG** – Jeu côlon

## Violin plots par cluster avec tests de significativité




FIGURE 36 – Expression de **IL2RA** par cluster avec significativité – Jeu multi-tissus




FIGURE 37 – Expression de **IL2RB** par cluster avec significativité – Jeu multi-tissus




FIGURE 38 – Expression de **IL2RG** par cluster avec significativité – Jeu multi-tissus




FIGURE 39 – Expression différentielle de **IL2RG** par cluster dans l'échantillon rénal – avec jitter et significativité.




FIGURE 40 – Expression différentielle de **IL2RB** par cluster dans l'échantillon rénal – avec jitter et significativité.




FIGURE 41 – Expression différentielle de **IL2RA** par cluster dans l'échantillon rénal – avec jitter et significativité.




FIGURE 42 – Expression différentielle de **IL2RA** par cluster – Jeu côlon . Les étoiles rouges indiquent une expression significativement plus élevée (test de Mann-Whitney,  $p < 0.05$ ).




FIGURE 43 – Expression de **IL2RB** par cluster avec significativité – Jeu colon




FIGURE 44 – Expression de **IL2RG** par cluster avec significativité – Jeu colon




FIGURE 45 – Expression de **IL2RA** par cluster avec significativité – Jeu embryon




FIGURE 46 – Expression de **IL2RB** par cluster avec significativité – Jeu embryon




FIGURE 47 – Expression de **IL2RG** par cluster avec significativité – Jeu embryon

## Heatmap de l'expression moyenne des marqueurs immunitaires




FIGURE 48 – Carte thermique représentant l'expression moyenne de marqueurs immunitaires par cluster dans l'échantillon multi-tissus. Chaque ligne correspond à un cluster et chaque colonne à un gène d'intérêt. La couleur indique le niveau moyen d'expression dans le cluster concerné.

## Annexe complémentaire – Analyse approfondie du jeu n°2

### UMAP colorée par origine tissulaire




FIGURE 49 – Projection UMAP annotée par origine tissulaire – Jeu *Human early embryogenesis*. Chaque couleur correspond à un tissu de provenance cellulaire.

### Analyse des profils d'expression par tissu

Le jeu n°2 inclut des métadonnées concernant l'origine tissulaire des cellules. Cette information a été utilisée pour colorer la carte UMAP selon les tissus d'origine, révélant une structuration partielle de l'espace transcriptomique par composante embryonnaire. Bien que les cellules immunitaires soient attendues principalement dans le compartiment sanguin, nous avons observé une expression significative des gènes IL2R dans d'autres tissus.

# Violin plots avec test de significativité




FIGURE 50 – Expression de **IL2RA** par tissu avec significativité – Jeu embryonnaire




FIGURE 51 – Expression de **IL2RB** par tissu avec significativité – Jeu embryonnaire




FIGURE 52 – Expression de **IL2RG** par tissu avec significativité – Jeu embryonnaire

Ces visualisations montrent que :

- **IL2RA** est significativement exprimé dans des tissus tels que le *limb* ou l'*endothelium*.
- **IL2RB** est retrouvé de manière significative dans des compartiments comme le *splanchnic LPM* ou le *somite*.
- **IL2RG**, bien qu'exprimé dans le sang, présente une expression significative dans de nombreux autres tissus, comme le *sensory neuron* ou le *craniofacial*.

## Conclusion complémentaire

Ces résultats suggèrent que nos méthodes d'annotation, initialement centrées sur les cellules immunitaires leucocytaires, doivent être élargies pour inclure d'autres types cellulaires exprimant des gènes IL2R. Pour cela, un enrichissement de notre base de gènes marqueurs s'impose afin d'annoter des cellules non immunitaires. Cela permettrait de mieux exploiter les potentialités de ce jeu de données riche mais actuellement sous-annoté.

## A Références bibliographiques

- [1] 10x Genomics. **Common Considerations for Quality Control Filters for Single Cell RNA-seq Data**. <https://www.10xgenomics.com/analysis-guides/common-considerations-for-quality-control-filters-for-single-cell-rna-seq-data>
- [2] Arwa D. **Understanding Quality Control in Single Cell RNA-Sequencing — Part 1**, LinkedIn. <https://www.linkedin.com/pulse/understanding-quality-control-single-cell-rna-sequencing-part-7hrec/>
- [3] Cao, J. et al. **The single-cell transcriptional landscape of mammalian organogenesis**. *Nature* 566, 496–502 (2019). <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8558157/>
- [4] Pythia Bio. **scRNA-seq analysis : FAQs and tips**. <https://www.pythiabio.com/post/scrna-seq-analysis-faqs-and-tips-to-avoid-common-pitfalls-part-1-quality-control>
- [5] Pedregosa et al. **Scikit-learn : Machine Learning in Python**. JMLR, 2011. <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.TruncatedSVD.html>
- [6] Luecken, M.D. & Theis, F.J. **Current best practices in single-cell RNA-seq analysis**. *MSB* (2019). <https://www.embopress.org/doi/full/10.15252/msb.20188746>
- [7] Becht, E. et al. **Dimensionality reduction using UMAP**. *Nat Biotechnol* 37, 38–44 (2019). <https://www.nature.com/articles/nbt.4314>
- [8] Zhang, X. et al. **CellMarker : a manually curated resource of cell markers**. *Nucleic Acids Res*, 2019. <http://bio-bigdata.hrbmu.edu.cn/CellMarker/>
- [9] Uhlén, M. et al. **The Human Protein Atlas**. <https://www.proteinatlas.org/humanproteome/single+cell/immune+cell>
- [10] Shao, X. et al. **scCATCH : Automatic Annotation of Cell Types**. *iScience*, 2020. [https://www.cell.com/iscience/fulltext/S2589-0042\(20\)30066-3](https://www.cell.com/iscience/fulltext/S2589-0042(20)30066-3)
- [11] Soneson, C., & Robinson, M. D. (2018). **Bias, robustness and scalability in single-cell differential expression**. *Nat Methods*, 15(4), 255–261. <https://www.nature.com/articles/nmeth.4612>
- [12] Wang, T., et al. (2019). **Comparative analysis of differential gene expression tools**. *BMC Bioinformatics*, 20(1), 40. <https://bmcbioinformatics.biomedcentral.com/articles/10.1186/s12859-019-2599-6>
- [13] McDavid, A., et al. (2013). **Testing in single-cell qPCR-based gene expression experiments**. *Bioinformatics*, 29(4), 461–467. <https://academic.oup.com/bioinformatics/article/29/4/461/228832>
- [14] Love, M. I., et al. (2014). **Moderated estimation for RNA-seq with DESeq2**. *Genome Biol*, 15(12), 550. <https://genomebiology.biomedcentral.com/articles/10.1186/s13059-014-0550-8>
- [15] Robinson, M. D., et al. (2010). **edgeR : differential expression analysis**. *Bioinformatics*, 26(1), 139–140. <https://academic.oup.com/bioinformatics/article/26/1/139/182458>
- [16] Wilcoxon, F. (1945). **Individual comparisons by ranking methods**. *Biometrics Bulletin*, 1(6), 80–83. <https://www.jstor.org/stable/3001968>